Premier League Kamp Prediktor

Alexander Rohde Jakobsen, Andreas Ødegård 30.10.26

Omfang:

I dette prosjektet ønsker vi å kunne forutsi utfallet av en Premier League-kamp. Brukeren skal kunne velge et hjemmelag og et bortelag, og systemet skal deretter beregne sannsynligheten for hjemmeseier, uavgjort og borteseier.

Vi mener at maskinlæring er en god tilnærming til dette problemet fordi historiske kampdata kan brukes til å utvikle og forbedre en modell som vurderer lagenes styrke. Vi bruker et Elo-system, der hvert lag får en rating basert på tidligere prestasjoner og kampresultater. Ratingene oppdateres etter hver kamp, slik at lag som presterer bedre enn forventet, får en høyere Elo-rating. Forskjellen i rating mellom lagene brukes så i en logistisk regresjon, som har lært av historiske kamper hvor sannsynlig hjemmeseier, borteseier og uavgjort er.

I dag finnes det flere nettsider som gir ut både bettings-tips og score predictions. Det finnes også steder som lar brukeren selv stemme på hva de tror kampresultatet blir.

Noen eksempler på eksisterende løsninger er:

- **Predicd:** Tilbyr prediksjoner av fotballkamper ved hjelp av en AI-basert modell. Plattformen presenterer forventede sluttresultater for kommende kamper, sammen med en vurdering av hvor safe prediksjonen er. Løsningen fokuserer dermed på konkrete resultatforslag, fremfor bare sannsynligheten for hjemmeseier, uavgjort og borteseier.
- **Sports4cast**: Bruker et 20 klubbers «promotion-relegation» system. Deres maskinlærings algoritme oppdateres daglig. På nettsiden deres kan vi se et spesifikt sluttresultat, men også en beregning på sannsynligheten for hjemmeseier, uavgjort og borteseier.

Disse løsningene viser at det allerede finnes et marked for digitale verktøy som forutser fotballresultater. Vårt prosjekt har et lignende formål, men bruker et elo-system for å måle lagenes styrke for å få en sannsynlighetsberegning på de tre mulige resultatene.

En måte man kan løse dette manuelt er som nevnt, en side hvor selv brukere kan stemme på hvilket lag de tror vinner. Vi brukte FotMob-appen til å finne ut hva folket spådde på de forskjellige Premier League-kampene den uken. For kampene vi så på, lå folkets spådommer nær våre egne. Folkene som går inn og stemmer har mest sannsynlig en interesse i fotball, og kan derfor spå en ganske så nøyaktig spådom. Dette løses helt uten noen tekniske verktøy, og kan være en enkel løsning på problemet vi prøver å løse.

Løsningen kan bli en stor suksess i markedet pga. det høye antallet som ser på og interesserer seg i Premier League og fotball generelt. Modellen vår gir brukerne beregnet estimerte sannsynligheter for kampenes sluttresultater. Dette kan være med på å styrke brukerens fotballforståelse, de kan bruke programmets prediksjon som utgangspunktet for diskusjoner og sammenligne det med deres egne vurderinger.

Produktet kan også være interessant for folk som er interessert i fotballstatistikk og betting. Modellen gir en statistisk vurdering av sannsynligheten for hjemmeseier, uavgjort og borteseier. Disse vurderingene er selvfølgelig ikke garantier, men kan gi brukeren et røft estimat på hvordan kampen kommer til å gå.

Pengespill kan være skadelig, så applikasjonen gir ikke spilleråd, og sannsynlighetene bør ikke brukes som grunnlag for å satse penger.

Systemet vårt består av flere komponenter som samarbeider for å beregne utfallet av en Premier League-kamp. Først henter vi tidligere kampresultater fra football-data.co.uk. Dataene blir dermed renset og gjøres klar til å brukes. Dette gjør vi ved å sørge for at datoer, lagnavn, og kamprekkefølger er riktige.

Videre bruker vi kampresultatene til å beregne lagenes Elo-ratinger. Forskjellen mellom lagene (EloDiff) er featuren i modellen som regner ut sannsynligheten. Vi testet også form, men det ga ingen forbedring (se kapittel 3). Til slutt presenteres prediksjonen i programmet.

Komponentene er avhengig av hverandre. Dersom det står en feil i databehandlingen, kan f.eks. kampene komme i feil rekkefølge. Dette er noe som kan påvirke Elo-ratingene. Man får en større belønning av å slå et lag med høyere elo-ratinger, hvis denne ratingen ikke stemmer, blir unøyaktighet i hele elo-systemet. Da kommer modellen med annerledes sannsynligheter og vi får prediksjoner som ikke er like nøyaktige som vi ønsker.

Metrikker:

Hovedmetrikken vår er log loss. For hver kamp ser vi på sannsynligheten modellen ga det som faktisk skjedde, og gir en straff ($-\ln p$) som blir større jo lavere sannsynligheten var. Scoren er snittet over alle kamper, og jo lavere scoren er jo bedre. Gir modellen 60 % til riktig utfall, koster det 0,51, mens 10 % koster 2,30. Å være sikker og ta feil koster altså mye. Å gi alle tre utfall en tredjedel gir 1,099.

Vi valgte log loss fordi produktet vårt er sannsynligheter, ikke enkelttips og skal ikke garantere resultater. Treffsikkerhet teller bare det mest sannsynlige utfallet, og kan derfor ikke belønne gode sannsynligheter. Vi rapporterer den likevel som støttemetrikk, siden den er lett å forstå.

Som benchmark bruker vi sannsynligheter regnet ut fra oddsene til Bet365. Løsningen er en suksess hvis den valgte modellen slår baselinen, logistisk regresjon på Elo med K = 20, på både validering og test. Bookmakeren har betydelig mer informasjon om hver kamp, skader, lagoppstillinger og overganger for eksempel, og dermed forventer vi ikke å slå dem. Applikasjonen er ikke lansert for ekte brukere, så forretningsmetrikker som antall brukere har vi ikke målt.

2.1 Kilde og omfang

Kilden vi bruker for å finne data og statistikk fra Premier League kamper fant vi på football-data.co.uk. Dette er en offentlig og tilgjengelig nettside der vi fant absolutt alle kamp resultater fra ligaen tilbake til 1990 tallet. Utenom det at denne siden var veldig enkel å bruke og gratis, så inneholdt den også data fra bookmakere, som vi da brukte som en benchmark for vår modell. Hver eneste sesong, notert for eksempel med 17/18 for sesongen som gikk over 2017-2018, var lastet opp som en E0.csv fil; vi brukte alle sesongene fra 2016/2017-2026/2027, og oppdelingen til hvordan vi brukte alle blir forklart i 2.2. Vi valgte å begynne med 16/17 sesongen for å holde modellen vår mer oppdatert, siden vi konkluderte at ligaen og lagene endrer seg mye, og at det ikke hadde vært særlig meningsfullt å sammenligne ett lag i dag sin prestasjon mot det samme laget 20 år før. Hver sesong har 380 kamper totalt, så over 10 sesonger hadde vi 3800 totalt, pluss 50 kamper fra den nåværende sesongen som bare brukes til å oppdatere lagenes nåværende Elo-rating i appen. Vår viktigste label er 'FTR' eller full-time result. Dette er det offisielle resultatet fra kampene som var i .csv filene, utrykket med (H/D/A) for hjemme seier, uavgjort eller borte seier. Labelen er altså gratis og helt konsekvent gjennom alle sesongene sine kamper, og krevde ingen manuell merking. Disse filene inneholdt veldig mange kolonner (skudd, kort, odds osv..), men det meste kunne vi ikke bruke. Det kommer mer om i 2.3. Sportsdataet er offentlig tilgjengelig uten personopplysninger, så GDPR gjelder heldigvis ikke.

2.2 Splitt per sesong

Sesong	**Rolle**	**Kamper**
2016/17	Bare oppvarming for Elo og form, ikke trening	380
2017/18 - 2023/24	Treningsdata	2660
2024/25	Validering: valg av features, K og modell	380
2025/26	Test, brukt til sluttallene, ikke til noen valg	380
2026/27	Ikke i noe sett, bare nåværende Elo-rating i appen	50

Tabell 1: Sesong splitt tabell

Vi valgte denne splitten for sesongene slik at modellen ikke skulle trene på kamper som er spilt etter kampene som modellen testes på. Dette hadde gitt modellen informasjon fra fremtiden, så scoren ville sett bedre ut enn den egentlig er. Oppvarmings sesong ble satt av slik at vi kunne varme opp Elo-ratingene på hvor gode alle lagene egentlig er, siden det naturligvis er noen lag i Premier League som er bedre enn andre. Alle lagene starter på samme nivå, 1500 Elo, i oppvarmings sesongen og dermed er EloDiff nesten 0 for alle kamper og sier ingenting om hvilket lag som er best. Etter en hel sesong med oppvarming har ratingene spredt seg og gjenspeiler nærmere faktisk lagstyrke. Hvis vi trente på 2016/17 sesongen, ville modellen lært fra kamper der featuren var meningsløs. 2025/26-sesongen ble brukt som testsesong og aldri til å ta valg. Valideringssesongen brukte vi flere ganger for å velge K og hvilken type modell vi ville bruke, så den scoren er litt optimistisk. Testscoren er derfor det ærligste tallet.

2.3 Leakage-regler og testene

For å unngå datalekkasje avklarte vi tidlig at en feature skulle bare være lov hvis det er kjent før avspark. Data eller statistikk som bare finnes etter en kamp kan vi ikke bruke til å predikere hvilket lag som kommer til å vinne. Sluttodds var noe vi så på og ikke tok med fordi det er publisert rett før avspark og ikke finnes når appen skal spå resultater dager i forveien. Mål, skudd, cornere, kort, fellinger og halvtidsresultat for eksempel var da ekskludert, siden disse beskriver kampen i seg selv. Vi brukte bookmaker odds som benchmark og aldri som input slik at modellen var vårt eget arbeid. Et annet eksempel på implementering av dette var i Form, som bruker shift(1) slik at en kamp aldri ser sitt eget resultat. Tilsvarende lagres Elo-rating før kampen, og oppdateres ikke før etter kampen er ferdig. Vi skrev noen tester som gjorde endringer i resultatet i en kamp og sjekker at kampens egne features er uendret, mens kamper som blir spilt senere påvirkes for både Elo og form. Elo-systemet viste seg å være en utfordrende mekanikk å implementere, siden vi oppdaget en stor bug underveis. Til å begynne med ble Elo-ratingene lagt til en liste i sortert rekkefølge, men festet til den usorterte tabellen etter posisjon. Dermed kunne kamper på samme dato få hverandres rating. Problemet løste vi

ved å lagre hver eneste rating under raden sin indeks, og lagde en test som stokker inputen for å bevise at det virker.

2.4 Rensing

Det var ett stort problem med dataet vi fant, og det ser vi i 2016/17 filen som skriver dato med 13/08/16, og sesonger som 11/08/2017. Parset feil kommer kampene da i feil rekkefølge, og Elo og form blir bygget fra feil historikk. Dette var en reell risiko, fordi rekkefølgen er hele grunnlaget til featurene. Løsningen vår besto av å bruke dayfirst=True, og format="mixed" for alle sesonger. Vi fjernet rader uten resultat og sorterte kampene stabilt etter dato. I appen oversettes lagnavnene til navnene som brukes i dataene.

2.5 Features

I begynnelsen starter alle lagene på 1500 Elo. Etter hver kamp flyttes poeng mellom lagene, så det ene laget sin gevinst er alltid det andre laget sitt tap. Vi valgte K = 30, som bestemmer hvor mye ett resultat kan flytte en rating. Hvor det tallet kommer fra blir snakket om i kapittel 3. Hver sesong rykker de tre nederste lagene ned, og tre nye lag rykker opp. Opprykkslagene starter på snittet til lagene som rykket ned, så totalen holder seg lik. Featuren modellen bruker er EloDiff, altså Elo forskjellen mellom lagene som spiller mot hverandre. Si vi har to lag på 1500 Elo hver, og hjemmelaget vinner. Forventet score er 0.5, og det faktiske resultatet er 1.0, så med K = 30 får hjemmelaget +15 Elo, og bortelaget får -15. Form er snittet av poengene fra lagets siste 5 ligakamper (shift(1) som nevnt i 2.3). Om et lag mangler form, for eksempel som de gjør i de første kampene deres i dataet, fylles med 0.79. Dette er det antatte poengsnittet til et typisk nedrykkslag (~30 poeng / 38 kamper).

Form ble testet som en annen feature, men er ikke med i den ferdige modellen (se kapittel 3).

3.1 Modeller og baselines

Vi testet to typer modeller. Den første er logistisk regresjon, der featurene skaleres med StandardScaler. Den andre er gradient boosting (HistGradientBoostingClassifier), som kan fange opp mer komplekse sammenhenger. Begge gir sannsynligheter for alle tre utfall.

Vi sammenlignet med tre referanser. Klassefrekvenser fra treningsdataene viser hva man får uten å vite noe om lagene. Dette tilsvarer å alltid tippe hjemmeseier, som ga 40,8 % treffsikkerhet på validering og 42,6 % på test. Logistisk regresjon på Elo med K = 20 er baselinen vi må slå. Bet365 er benchmarken. Oddsene er aldri input til modellen.

Før vi så resultatene bestemte vi at en forskjell under 0,005 i log loss regnes som uavgjort, og at den enkleste modellen da vinner.

3.2 Resultater på validering (2024/25)

Modell	Log loss	Treffsikkerhet
Bet365 (Benchmark)	0,9708	54,2%
Logistisk regresjon, Elo + Form	0,9763	54,0%
Logistisk regresjon, Elo (valgt)	0,9774	53,7%
Logistisk regresjon, Elo, K = 20 (baseline)	0,9819	53,2%
Gradient boosting, Elo	0,9926	54,0%
Gradient boosting, Elo + Form	0,9956	53,4%
Logistisk regresjon, Form	1,0429	49,2%
Klassefrekvenser	1,0809	40,8%

Tabell 2: Log loss tabell og treffsikkerhet på valideringssesong 2024/25. Alle modeller bruker K = 30, med mindre annet står

Vi testet også målforskjell som form, hjemmefordel i Elo, Elo vektet etter målforskjell og å trekke ratingene mot snittet mellom sesonger. Det eneste som ga en reell forbedring var høyere K: alle verdier fra 25 til 35 slo K = 20, så effekten er ikke tilfeldig. Med K = 30 gikk log loss ned 0,0046. Høyere K lar ratingene følge lagenes styrke raskere.

Elo og form var bare 0,0011 bedre enn Elo alene, altså uavgjort etter regelen vår, så den enkleste modellen vant. Form tilfører lite fordi et lag i god form allerede har stigende Elo. Gradient boosting var omtrent 0,015 dårligere enn logistisk regresjon på samme feature. Sammenhengen er jevn, så den ekstra fleksibiliteten tilpasser seg trolig bare støy i 2 660 treningskamper. Vår valgte modell ble derfor logistisk regresjon på EloDiff med K = 30.

3.3 Sluttresultat på test (2025/26)

Her ble modellene trent på 2017/18–2024/25.

Modell	Log loss	Treffsikkerhet
Bet365 (Benchmark)	1,0185	49,0%
Logistisk regresjon, Elo, K = 30 (valgt)	1,0385	48,7%
Logistisk regresjon, Elo, K = 20 (baseline)	1,0405	47,4%

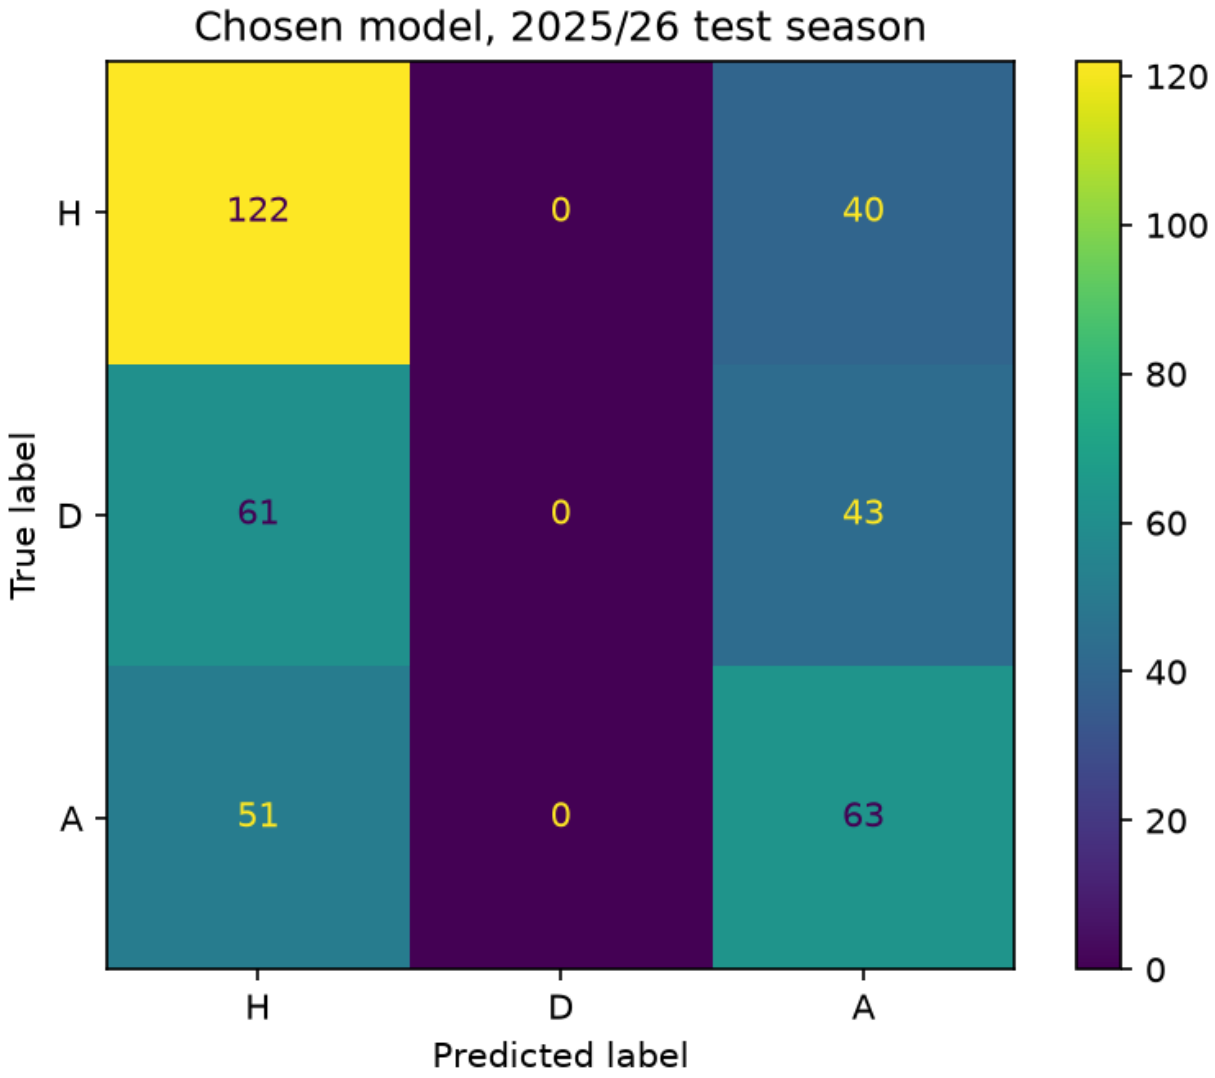
Klassefrekvenser	1,0850	42,6%

Tabell 3: Log loss tabell og treffsikkerhet på testsesongen 2025/26. Lavere log loss er bedre.

Modellen slår baselinen på både validering og test, så suksesskriteriet er oppfylt. Den tetter 70 % av gapet mellom klassefrekvenser og Bet365 på test, mot 94 % på validering. Treffsikkerheten er på nivå med Bet365, selv om modellen bare bruker én feature. Gevinsten fra K = 30 krympet fra 0,0046 til 0,0020, noe vi forventet siden K ble valgt etter mange titt på valideringen. Også Bet365 ble dårligere fra validering til test (0,971 til 1,019), så 2025/26 var rett og slett vanskeligere å forutsi. Modellen mistet likevel mer enn Bet365. Elo kan ikke fange opp endringer som nye trenere og overganger.

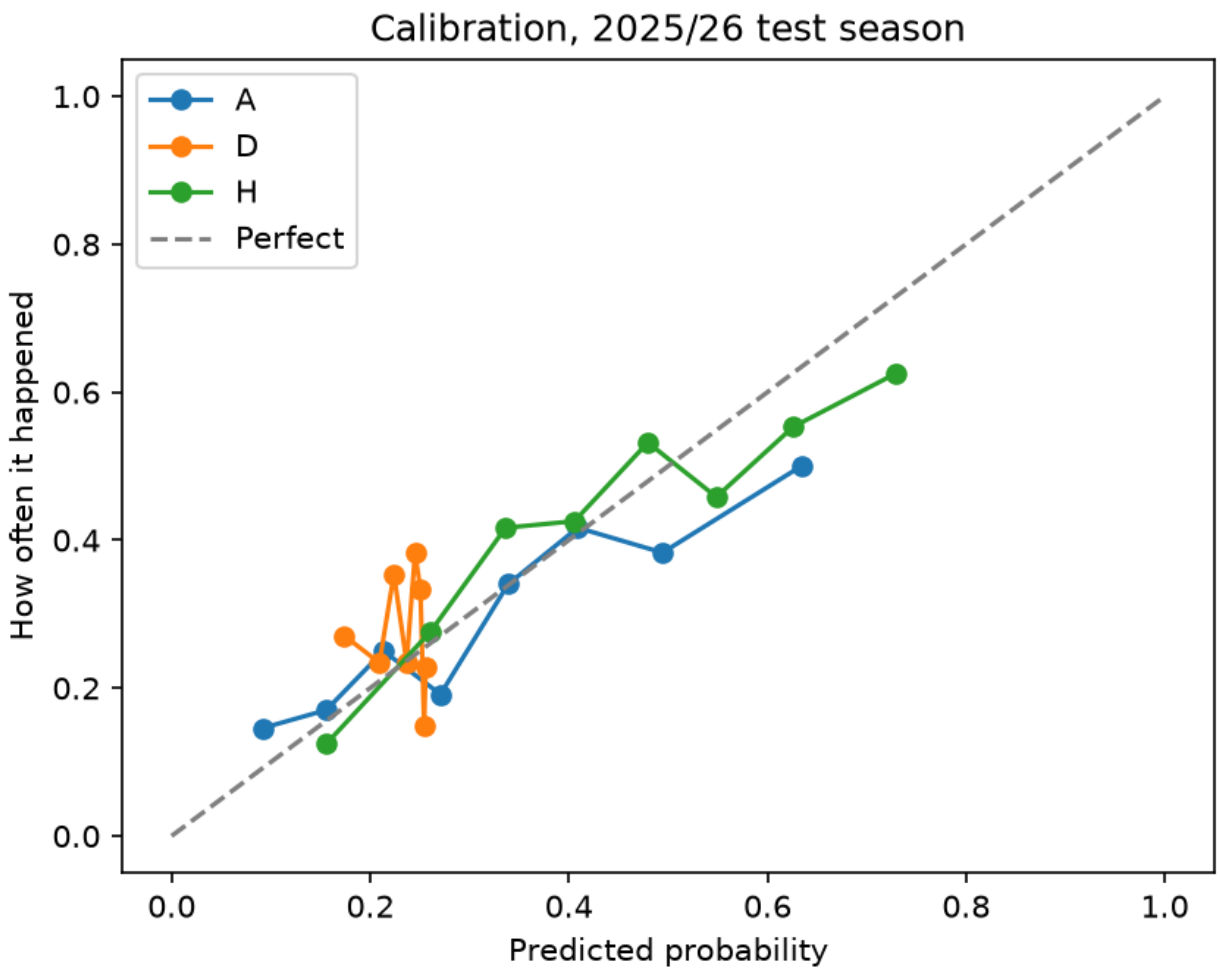
Under kontrollen av scorefunksjonen ble K = 20 og K = 30 også scoret på testsesongen, og sluttskriptet ble kjørt to ganger fordi første kjøring krasjet. Ingen valg ble tatt ut fra dette, og modellen ble ikke endret etter testen.

3.4 Feilanalyse



Figur 3.1: Confusion matrix

Figur 3.1 viser at modellen aldri tipper uavgjort, selv om 104 av 380 testkamper (27,4 %) endte slik. Det gjør heller ikke Bet365 på testsesongen. Årsaken er at uavgjort sjelden er det enkeltutfallet som er mest sannsynlig: modellens høyeste sannsynlighet for uavgjort i en testkamp var 25,6 %. Dette er ikke en feil, og det er en av grunnene til at vi bruker log loss. Modellen ga uavgjort 23,1 % i snitt, omtrent som i treningsdataene (22,9 %), men testsesongen hadde uvanlig mange uavgjorte kamper.



Figur 3.2: Kalibrering på test sesong

Figur 3.2 viser at sannsynlighetene for hjemme- og borteseier følger diagonalen ganske godt opp til rundt 50 %. Ved store favoritter er modellen litt for sikker: når den sier 73 % hjemmeseier, skjedde det i 62 % av tilfellene. Hvert punkt bygger på omtrent 47 kamper, så dette er en indikasjon, ikke et bevis.

Siden modellen bare har én feature, er feature importance ikke særlig relevant. Forsøkene over viser likevel at Elo gjør nesten alt arbeidet: Elo alene tetter 94 % av gapet på validering, mens form nesten ikke tilfører noe. Ratingene stemmer også godt med tabellen: Man City, Arsenal og Man United har høyest Elo og var topp tre i 2025/26. En svakhet er at Elo er treg etter overraskelser. Sunderland rykket opp og ble nummer 7, men har fortsatt en rating under snittet. Vi ser dette som en begrensning og justerte ikke modellen, for da ville testtallet ikke

lenger vært pålitelig. For å forbedre modellen trenger den informasjon som skader, lagoppstillinger og overganger.

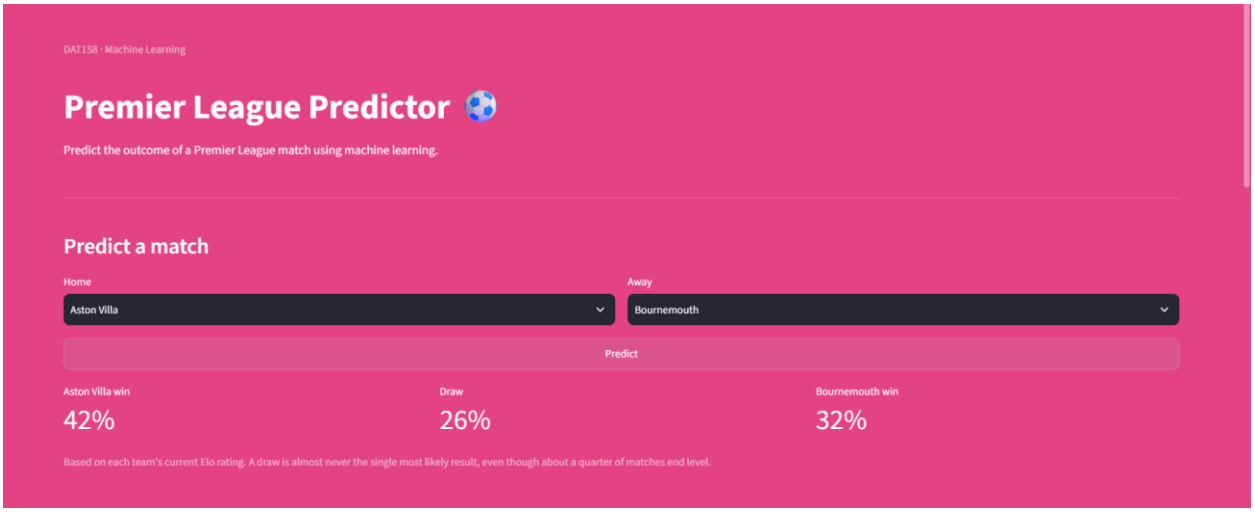
Modellen er implementert i en applikasjon utviklet med Streamlit og er satt i drift på Streamlit Community Cloud: https://beste-dat158-prosjekt.streamlit.app/.

Brukeren kan velge et hjemmelag og et bortelag fra Premier League, og få sannsynligheten for hjemmeseier, uavgjort og borteseier. Resultatet vises som tre prosenter i applikasjonen.

For å opprettholde og vedlikeholde systemet må dataen oppdateres hyppig, slik at de nyeste kampresultatene er med i beregningen av de neste kampene. Programmet trenger derfor den nyeste dataen. Da er det viktig at denne dataen blir behandlet riktig, og at applikasjonen fortsatt beregner sannsynligheten som den gjorde før.

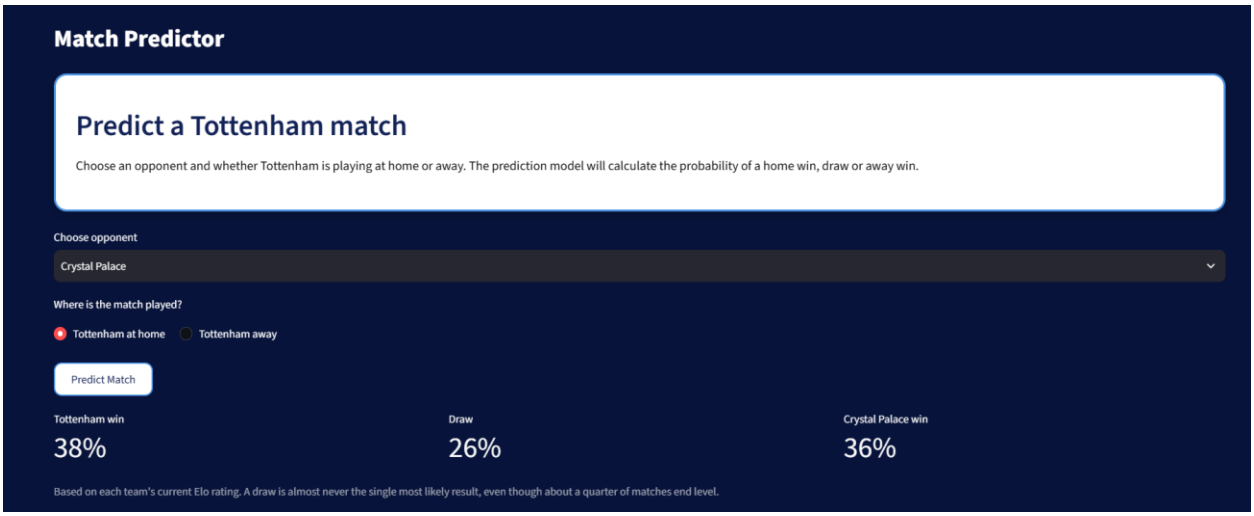
Over tid kan vi sammenligne modellens prediksjoner med faktiske kampresultater og se om den holder seg stabil. Hvis modellen presterer dårligere enn forventet kan vi eventuelt se på årsakene og vurdere om det er noe vi trenger å justere på.

Figur 4.1 er fra fremsiden vår. Man kan velge et hjemmelag og et bortelag og deretter trykke på «predict». Så kommer sannsynlighetene for hjemmeseier, uavgjort og borteseier opp.



Figur 4.1

Hvert topp-6 lag har hver sin side, her står det informasjon om klubben og man kan predikere kampene deres direkte inne på siden. Figur 4.2 tar for seg Tottenham-siden.



Figur 4.2

Figur 4.3 viser at løsningen tar for seg om laget spiller på hjemme- eller bortebane. Tottenham har større sjanse for å vinne kampen når de spiller på hjemmebane enn når de spiller på bortebane.



Figur 4.3

Målet med produktet er å kunne gi fotballinteresserte en enkel måte å undersøke sannsynlighet for ulike utfall av Premier League-kamper på. Dersom løsningen skulle blitt utviklet videre

kunne vi tilbudt en nettside med mer statistikk og kampanalyser. Noe som hadde vært gøy å utvikle hadde vært å samle inn data, ikke bare om kampene, men også spillerne, og lage et nettsted som viser sjansen for at spesifikke spillere scorer eller får gule og røde kort.

Fantasy Premier League er populært og spilles av millioner av mennesker. Det går ut på å velge de riktige spillerne, som får mest poeng. Poeng får de av å score mål, få assist, holde et rent bur og generelt spille en bra kamp. Her finnes det muligheter for å videreutvikle løsningen vår enda mer. Modellen kan ta inn data om spillerne og gi en prediksjon på hvor mange poeng den tror spilleren får i løpet av en kamp.

Referanseliste:

Anthropic. (2026). Claude [KI-verktøy]. https://claude.ai. Brukt til kodehjelp, gjennomgang av kode og rapport, og utkast til deler av rapportteksten.

Elo, A. E. (1978). The Rating of Chessplayers, Past and Present. Arco.

Football-Data.co.uk. (2026). England football results. https://www.football-data.co.uk/englandm.php

FotMob. (2026). FotMob. https://www.fotmob.com

Pedregosa, F. mfl. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Predicd. (2026). https://www.predicd.com/en/football/

Sports4cast. (2026). https://sports4cast.com/

Streamlit. (2026). Streamlit documentation. https://docs.streamlit.io